

LAPORAN TEKNIS KOMPREHENSIF

CODING CAMP 2026 POWERED BY DBS FOUNDATION

ID Tim Capstone Project: CC26-PSU353

Judul Proyek : CortiSoul

Tema yang Dipilih : Healthy Lives & Well-being

List Anggota :

1. CDCC284D6Y0378 - Moh Annas Shobari - Data Science - **[Aktif]**
2. CDCC641D6X0732 - Linda Putriani - Data Science - **[Aktif]**
3. CFCC324D6Y1878 - Reisya Pratama - Full-Stack Web Developer - **[Aktif]**
4. CFCC641D6Y0666 - Adriyan - Full-Stack Web Developer - **[Aktif]**
5. CACC284D6Y1512 - Rizki Wahyu Widodo - AI Engineer - **[Aktif]**
6. CACC319D6Y1496 - Ahmad Rozan Raufansyah Nasution - AI Engineer - **[Aktif]**

1. Pendahuluan

1.1. Latar Belakang

Kesehatan mental merupakan salah satu isu yang semakin mendapat perhatian di Indonesia, khususnya di kalangan generasi muda. Tingginya tingkat stres, kecemasan, dan depresi yang dialami masyarakat tidak diimbangi dengan akses yang memadai terhadap layanan kesehatan mental profesional, baik dari segi biaya maupun stigma sosial yang masih kuat.

Journaling atau menulis jurnal harian telah terbukti secara ilmiah sebagai salah satu metode expressive writing yang efektif untuk membantu individu mengekspresikan perasaan, mengurangi beban emosional, dan meningkatkan kesadaran diri [1]. Dengan memanfaatkan teknologi Natural Language Processing (NLP) dan machine learning, platform journaling dapat ditingkatkan

kemampuannya untuk memahami kondisi emosioanal pengguna secara otomatis dan memberikan respons yang personal.

1.2. Pertanyaan Bisnis

Pertanyaan bisnis ini disusun menggunakan kerangka SMART (Specisif, Measurable, Action-Oriented, Relevant, Time-Bound) untuk memastikan arah pengembangan proyek yang teratur dan dapat dieksekusi :

- Token atau frasa apa yang paling merepresentasikan masing-masing dari 7 kategori kondisi mental, berdasarkan analisis Word2Vec dan FastText (top-10 kata paling mirip per kategori) pada dataset 9.151 entri CortiSoul yang telah melalui preprocessing Sastrawi + stopword removal + stemming, sebagai dasar feature engineering dan interpretasi model selama fase EDA proyek CortiSoul?
- Bagaimana model NLP menggunakan representasi vektor Word2Vec dan FastText (vector_size=100, window=5) dapat mengklasifikasikan 7 kondisi mental (Anxiety, Normal, Depression, Stress, Personality Disorder, Bipolar, Suicidal) dari teks journaling berbahasa Indonesia dengan akurasi minimal 80% dan F1-score $\geq 0,75$ pada dataset 9.152 entri hasil preprocessing Sastrawi, selama fase pemodelan pada periode pengembangan proyek CortiSoul?

1.3. Tujuan Proyek

- Membangun model klasifikasi sentimen berbahasa Indonesia yang mampu mengidentifikasi emosi pengguna dari teks jurnal harian.
- Mengembangkan platform journaling digital yang memberikan respons emosional yang personal berdasarkan hasil analisis sentimen
- Melakukan evaluasi dan perbandingan metode vectorization melalui A/B Testing untuk menentukan pendekatan terbaik

- Men-deploy platform sebagai aplikasi web yang dapat diakses secara publik

1.4. Ruang Lingkup Proyek

- Dataset : Teks berbahasa Indonesia dengan 7 kategori kondisi mental
- Preprocessing : Cleaning hingga stemming menggunakan PySastrawi
- Modelling : Ekspreimentasi beberapa algoritma klasifikasi
- A/B Testing : perbandingan Word2Vec vs FastText
- Deployment : Aplikasi web menggunakan streamlit Cloud

2. Problem Discovery

2.1. Identifikasi Masalah

Berdasarkan data Kementerian Kesehatan Indonesia, hampir 20% penduduk Indonesia mengalami gangguan mental emosional, namun hanya sekitar 8% di antaranya yang mendapatkan penanganan profesional [2]. Kesenjangan yang besar ini mencerminkan kompleksitas krisis kesehatan mental di Indonesia, yang salah satunya dipicu oleh kurangnya akses terhadap ruang-ruang pemulihan, baik berupa layanan kesehatan yang terjangkau maupun ruang publik yang mendukung relaksasi dan kesejahteraan psikologis.

Media sosial dan platform digital menjadi salah satu outlet utama bagi masyarakat untuk mengekspresikan perasaan mereka. Hal ini membuka peluang untuk memanfaatkan teknologi NLP guna memami kondisi emosional pengguna secara non-invasif.

3. Data Understanding

3.1. Sumber dan Deskripsi Dataset

Dataset yang digunakan dalam proyek ini merupakan kumpulan teks berbahasa Indonesia yang merepresentasikan berbagai kondisi emosional dan kesehatan mental. Data dikumpulkan dari website kaggle yang relevan dengan topik kesehatan mental.

Atribut	Keterangan
Jumlah data	9.163 Baris
Jumlah Kolom	2 Kolom (text_id, status)
Bahasa	Indonesia
Jumlah Kategori	7 Kategori kondisi mental

3.2. Distribusi Label

Dataset memiliki distribusi label yang relatif seimbang antar kategori, yang penting untuk memastikan model tidak bias terhadap kategori tertentu.

Kategori	Jumlah Data	Persentase
Suicidal	1.657	18,13%
Depression	1.635	17,89%
Personality Disorder	1.234	13,51%
Normal	1.237	13,54%
Stress	1.236	13,53%
Anxiety	1.198	13,11%
Bipolar	966	10,57%
Total	9.163	100%

3.3. Data Dictionary

Dataset ini memiliki 2 kolom utama, yaitu :

Kolom	Pengertian
Text	Berisi teks mentah yang mencerminkan pengalaman pribadi, ekspresi emosi, atau gejala yang dirasakan oleh individu
Status	Berisi label kondisi mental yang digunakan sebagai target klasifikasi

Label pada kolom status terdiri dari beberapa kategori, yaitu :

Kategori	Pengertian
Anxiety	perasaan cemas, khawatir, atau gelisah
Normal	Kondisi emosional yang netral
Depression	Kondisi sedih berkepanjangan atau kehilangan minat
Stress	Kondisi tekanan atau beban mental
Personality Disorder	Gangguan pola perilaku dan emosi
Bipolar	Perubahan suasana hati ekstrem antara depresi dan mania
Suicidal	Indikasi keinginan untuk menyakiti diri sendiri

3.4. Alasan pemilihan dataset

Dataset ini dipilih karena mencakup spektrum kondisi kesehatan mental yang luas dan relevan dengan tujuan platform journaling. Keberagaman kategori memungkinkan model untuk membedakan berbagai kondisi emosional secara granular, sehingga intervensi yang diberikan dapat lebih tepat sasaran.

4. Preprocessing

Preprocessing merupakan tahap krusial dalam pipeline NLP yang bertujuan untuk membersihkan dan menyederhanakan teks sebelum diproses oleh model machine learning. Setiap langkah dilakukan secara berurutan untuk memastikan kualitas data yang optimal.

4.1. Data Cleaning

Tahap pertama adalah membersihkan teks dari elemen-elemen yang tidak relevan untuk analisis sentimen. Elemen yang dihapus meliputi URL, mention (@), hashtag, emoji, karakter selain huruf, spasi berlebih, retweet.

	text	clean_text
0	Saya tidak tahu apakah ini kedengarannya bodoh...	Saya tidak tahu apakah ini kedengarannya bodoh...
1	pikiranku bagaikan badai yang kacau, melempark...	pikiranku bagaikan badai yang kacau melemparka...
2	Pada suatu saat saya dilanda gelombang kreativ...	Pada suatu saat saya dilanda gelombang kreativ...
3	jadi teman saya sedang mengalami masa sulit, d...	jadi teman saya sedang mengalami masa sulit di...
4	Aku terpecah antara siapa aku sebenarnya dan i...	Aku terpecah antara siapa aku sebenarnya dan i...

4.2. Case Folding

Seluruh teks diubah ke huruf kecil untuk memastikan konsistensi, sehingga kata 'Bagus' dan 'bagus' diperlakukan sebagai token yang sama oleh model.

	clean_text	lower
0	Saya tidak tahu apakah ini kedengarannya bodoh...	saya tidak tahu apakah ini kedengarannya bodoh...
1	pikiranku bagaikan badai yang kacau melemparka...	pikiranku bagaikan badai yang kacau melemparka...
2	Pada suatu saat saya dilanda gelombang kreativ...	pada suatu saat saya dilanda gelombang kreativ...
3	jadi teman saya sedang mengalami masa sulit di...	jadi teman saya sedang mengalami masa sulit di...
4	Aku terpecah antara siapa aku sebenarnya dan i...	aku terpecah antara siapa aku sebenarnya dan i...

4.3. Normalisasi Kata Slang

Tweet berbahasa Indonesia banyak menggunakan kata slang dan singkatan informal seperti 'gak', 'yg', 'bgt', dan sebagainya. Normalisasi dilakukan menggunakan kamus slang yang dikembangkan secara manual untuk mengubah kata-kata tersebut ke bentuk baku.

	lower	normalized
0	saya tidak tahu apakah ini kedengarannya bodoh...	saya tidak tahu apakah ini kedengarannya bodoh...
1	pikiranaku bagaikan badai yang kacau melemparka...	pikiranaku bagaikan badai yang kacau melemparka...
2	pada suatu saat saya dilanda gelombang kreativ...	pada suatu saat saya dilanda gelombang kreativ...
3	jadi teman saya sedang mengalami masa sulit di...	jadi teman saya sedang mengalami masa sulit di...
4	aku terpecah antara siapa aku sebenarnya dan i...	saya terpecah antara siapa saya sebenarnya dan...

4.4. Tokenisasi

Teks dipecah menjadi unit-unit kata individual (token) menggunakan library NLTK dengan metode word_tokenize yang mendukung teks berbahasa Indonesia.

	tokens	normalized
0	[saya, tidak, tahu, apakah, ini, kedengarannya...	saya tidak tahu apakah ini kedengarannya bodoh...
1	[pikiranaku, bagaikan, badai, yang, kacau, mele...	pikiranaku bagaikan badai yang kacau melemparka...
2	[pada, suatu, saat, saya, dilanda, gelombang, ...	pada suatu saat saya dilanda gelombang kreativ...
3	[jadi, teman, saya, sedang, mengalami, masa, s...	jadi teman saya sedang mengalami masa sulit di...
4	[saya, terpecah, antara, siapa, saya, sebenarn...	saya terpecah antara siapa saya sebenarnya dan...

4.5. Stopword Removal

Kata-kata yang tidak memberi makna sentimen seperti 'dan', 'yang', 'di', 'ke', 'ini', dan 'itu' dihapus menggunakan daftar stopwords bahasa Indonesia dari library PySastrawi. Penghapusan stopwords membantu model untuk fokus pada kata-kata yang benar-benar bermakna.

	text_no_stopword	tokens
0	kedengarannya bodoh gunanya mencoba mencapai u...	[saya, tidak, tahu, apakah, ini, kedengarannya...
1	pikiranku badai kacau melemparkanku penyesalan...	[pikiranku, bagaikan, badai, yang, kacau, mele...
2	dilanda gelombang kreativitas produktivitas di...	[pada, suatu, saat, saya, dilanda, gelombang, ...
3	teman mengalami sulit bantuan dukungan memutus...	[jadi, teman, saya, sedang, mengalami, masa, s...
4	terpecah emosiku asli topeng lepas	[saya, terpecah, antara, siapa, saya, sebenarn...

4.6. Stemming

Setiap token diubah ke bentuk kata dasarnya menggunakan PySastrawi Stemmer. Contohnya, kata 'berlari', 'lari-lari', dan 'berlarian' semuanya dikembalikan ke bentuk dasar 'lari'. Stemming membantu mengurangi dimensionalitas fitur dan meningkatkan generalisasi model.

	text_stemmed	text_no_stopword
0	dengar bodoh guna coba capai usia dewasa dunia...	kedengarannya bodoh gunanya mencoba mencapai u...
1	pikir badai kacau lempar sesal takut buat daya...	pikiranku badai kacau melemparkanku penyesalan...
2	landa gelombang kreativitas produktivitas land...	dilanda gelombang kreativitas produktivitas di...
3	teman alami sulit bantu dukung putus tulis pui...	teman mengalami sulit bantuan dukungan memutus...
4	pecah emosi asli topeng lepas	terpecah emosiku asli topeng lepas

4.7. Filter Token Pendek

Token dengan panjang kurang dari 3 karakter dihapus karena umumnya tidak membawa makna yang signifikan dan hanya menambah noise pada data


	text_preprocessed	text_stemmed
0	dengar bodoh guna coba capai usia dewasa dunia...	dengar bodoh guna coba capai usia dewasa dunia...
1	pikir badai kacau lempar sesal takut buat daya...	pikir badai kacau lempar sesal takut buat daya...
2	landa gelombang kreativitas produktivitas land...	landa gelombang kreativitas produktivitas land...
3	teman alami sulit bantu dukung putus tulis pui...	teman alami sulit bantu dukung putus tulis pui...
4	pecah emosi asli topeng lepas	pecah emosi asli topeng lepas

5. Eksploratory Data Analysis (EDA)

5.1. Distribusi Label

Analisis distribusi label dilakukan untuk memahami sebaran jumlah data pada setiap kategori kondisi mental dalam dataset. Berdasarkan hasil analisis, kategori suicidal memiliki jumlah data terbanyak dengan 1.657 entri (18,1%), diikuti oleh kategori depression sebanyak 1.635 entri (17.9%). Sementara itu, kategori bipolar memiliki jumlah data paling sedikit yakni 966 entri (10.6%). Secara keseluruhan, distribusi antar kategori relatif seimbang dengan rasio imbalance yang masih dapat ditoleransi, sehingga tidak diperlukan teknik penanganan class imbalance seperti oversampling atau undersampling.

Distribusi kondisi mental:

suicidal	1657	(18.1%)	
depression	1635	(17.9%)	
normal	1237	(13.5%)	
personality disorder	1234	(13.5%)	
stress	1233	(13.5%)	
anxiety	1190	(13.0%)	
bipolar	966	(10.6%)	

5.2. Word Cloud Per Kategori

Word cloud digunakan untuk memvisualisasikan kata-kata yang paling sering muncul pada masing-masing kategori. Dari analisis ini terlihat pola kata yang khas per kategori, misalnya kata 'pikir', 'takut', dan 'khawatir' dominan pada kategori anxiety, sementara kata 'hidup', 'laku', dan 'pikir' muncul dominan pada kategori depression. Pada kategori suicidal, kata 'bunuh', 'hidup', dan 'mati' mendominasi, sedangkan kategori bipolar ditandai dengan kata 'ganggu', 'kreativitas', dan 'produktivitas'. Kategori personality disorder didominasi kata 'tatap', 'balas', dan 'identitas', kategori normal menampilkan kata 'tidur', 'banget', dan 'suka', sementara kategori stress didominasi kata 'tanggung', 'tenggelam', dan 'henti'."

[illegible]

Analisis frekuensi kata dilakukan untuk mengidentifikasi kata-kata yang paling informatif dalam dataset. Temuan ini digunakan sebagai dasar untuk mengatur parameter `max_features` pada proses vectorization.

Kata	Frekuensi
pikir	4,959
orang	4,179
hidup	3,841
buat	2,527
diri	2,494
takut	2,087
buruk	1,825
laku	1,805
bunuh	1,723
temu	1,677
mati	1,605
depresi	1,570
penuh	1,554
coba	1,528
sakit	1,488
henti	1,484
asa	1,381
benarbenar	1,372
harap	1,340
kerja	1,289

5.4. Temuan dan Insight EDA

- Dataset memiliki distribusi label yang relatif seimbang, sehingga tidak memerlukan teknik oversampling/undersampling
- Setiap kategori memiliki pola kosakata yang cukup distingtif, mengindikasikan bahwa model klasifikasi berpotensi memberikan performa yang baik
- Panjang teks bervariasi antar kategori, yang perlu dipertimbangkan dalam pemilihan parameter tokenisasi.

6. Vectorization

Vektorisasi adalah proses pengubahan data teks menjadi representasi numerik yang dapat diolah oleh algoritma machine learning [3]. Dua metode vectorization berbasis word embedding digunakan dalam proyek ini untuk kemudian dibandingkan melalui A/B Testing, yaitu Word2Vec dan FastText.

6.1. Word2Vec

Word2vec merupakan teknik yang digunakan untuk merepresentasikan vektor yang berasal dari kata dalam suatu teks. Pada langkah teknik Word2vec, hasil teks abstrak yang sudah dilakukan pra-pemrosesan akan direpresentasikan menjadi vektor. Word2vec menggunakan jaringan saraf tiruan untuk mempelajari representasi vektor kata dari korpus besar. Kata-kata direpresentasikan sebagai one-hot encoding, dan jaringan dilatih dengan algoritma backpropagation [4].

6.2 FastText

FastText merupakan perpanjangan dari library Word2vec yang didasarkan pada kontinuitas skip-gram dimana setiap kata akan direpresentasikan sebagai karakter n-gram [5].

6.3 Parameter Vectorization

Parameter	Nilai	Alasan
vector_size	100	Dimensi vektor yang cukup representatif tanpa terlalu berat secara komputasi.
window	5	Mempertimbangkan konteks 5 kata di kiri dan kanan kata target

min_count	2	Mengabaikan kata yang hanya muncul 1 kali dalam korpus (noise)
workers	4	Jumlah thread paralel untuk mempercepat proses training
seed	42	Memastikan reproducibility hasil eksperimen

7. Modelling

Tahap modeling bertujuan untuk membangun model klasifikasi yang mampu mengidentifikasi kategori emosi dari teks jurnal pengguna. Kami menggunakan algoritma BiLSTM untuk modellingnya.

7.1. Algoritma yang digunakan

Proyek ini menggunakan Bidirectional Long Short-Term Memory (BiLSTM) sebagai model klasifikasi utama. BiLSTM adalah perkembangan dari model LSTM di mana terdapat dua lapisan yang prosesnya saling berkebalikan arah, model ini sangat baik untuk mengenali pola dalam kalimat karena setiap kata dalam dokumen diproses secara sekuensial, karena cuitan dapat dipahami bila pembelajaran secara berurut setiap kata [6]. Kemampuan ini menjadikan BiLSTM sangat efektif untuk tugas klasifikasi teks berbahasa Indonesia yang memiliki struktur kalimat kompleks.

7.2. Pembagian Data


Split	Proporsi	Jumlah Data
Training Set	80%	7321 baris
Testing Set	20%	1830 baris

7.3. Hasil Evaluasi Model

Kategori	Accuracy	Precision	Recall	F1-Score
anxiety	0,99	0,97	0,98	178
bipolar	1,00	1,00	1,00	145

depression	0,73	0,47	0,57	246
normal	0,98	0,99	0,99	305
personality disorder	0,99	1,00	1,00	185
stress	0,99	0,99	0,99	185
suicidal	0,61	0,83	0,71	249
Accuracy			0,88	1493
Macro Avg	0,90	0,89	0,89	1493
Weighted Avg	0,88	0,88	0,87	1493

7.4. Confusion Matrix



8. A/B Testing

A/B testing dalam konteks machine learning merupakan metode eksperimen yang membandingkan performa dua model atau algoritma dalam lingkungan produksi[7]. A/B Testing dilakukan untuk membandingkan secara objektif dua metode vectorization dengan menggunakan model yang identik sebagai alat ukur. Dengan mengisolasi variabel vectorization, perbedaan performa yang terukur dapat diatribusikan sepenuhnya pada metode vectorization yang digunakan.

8.1. Desain Eksperimen

A/B Testing dilakukan untuk membandingkan secara objektif dua metode vectorization dengan menggunakan model yang identik sebagai alat ukur. Dengan mengisolasi variabel vectorization, perbedaan performa yang terukur dapat diatribusikan sepenuhnya pada metode vectorization yang digunakan.


	Kondisi A	Kondisi B
Vectorization	Word2Vec	FastText
Model	Logistic Regression	Logistic Regression
Parameter Vectorization	Vector_size=100, window=5, min_count=2, seed=42	Vector_size=100, window=5, min_count=2, seed=42
Parameter Model	max_iter=1000, random_state=42	max_iter=1000, random_state=42
Data Split	80:20, random_state=42	80:20, random_state=42

8.2. Hasil Perbandingan

Hasil perbandingan antara kondisi A dan kondisi B dianalisis menggunakan dua pendekatan yang saling melengkapi. Pertama, perbandingan secara global menggunakan empat metrik standar yaitu Accuracy, Precision, Recall, dan F1-Score untuk melihat performa secara keseluruhan dari kedua metode. Kedua, perbandingan secara granular menggunakan F1-Score per kelas untuk mengidentifikasi secara spesifik kategori kondisi mental mana yang lebih baik dikenali oleh masing-masing metode vectorization.

Tabel berikut menyajikan hasil perbandingan global antara kondisi A dan kondisi B :


Metrik	Kondisi A (Word2Vec)	Kondisi B (FastText)	Selisih (B - A)
Accuracy	0.8064	0.7945	-0.0119
Precision	0.8079	0.7957	-0.0122
Recall	0.8064	0.7945	-0.0119
F1-Score	0.8070	0.7949	-0.0120



Selanjutnya, perbandingan F1-Score per kelas disajikan pada tabel berikut:

Kelas	Kondisi A (Word2Vec)	Kondisi B (FastText)	Selisih (B - A)
anxiety	0.9302	0.9149	-0.0152
bipolar	0.9799	0.9742	-0.0057
depression	0.6027	0.5770	-0.0257
normal	0.7506	0.7460	-0.0046
personality disorder	0.9698	0.9661	-0.0037
stress	0.9638	0.9569	-0.0069

suicidal	0.6224	0.6070	-0.0154
----------	--------	--------	---------



8.3. Uji Statistik – McNemar Test

Untuk memastikan bahwa perbedaan performa antara kedua kondisi bukan hanya kebetulan, dilakukan uji statistik menggunakan McNemar Test dengan hipotesis:

- H0: Tidak ada perbedaan signifikan antara Word2Vec dan FastText
- H1: Ada perbedaan signifikan antara Word2Vec dan FastText

Statistik	Nilai
McNemar Statistic	14,4894
P-value	0,0001
Signifikan ($p < 0.05$)?	Ya

8.4. Kesimpulan A/B Testing

Berdasarkan hasil perbandingan metrik dan uji statistik McNemar Test, dapat disimpulkan bahwa perbedaan performa antara Vectorization dan FastText pada dataset ini tergolong signifikan secara statistik. Hal ini mengindikasikan bahwa pada teks pendek berbahasa Indonesia, metode Vectorization Word2Vec lebih unggul daripada metode FastText.

9. Dashboard & Deployment

Tahap akhir proyek CortiSoul adalah mengemas seluruh hasil analisis, pemodelan, dan insight ke dalam sebuah aplikasi web interaktif yang dapat diakses pengguna secara langsung tanpa instalasi apapun. Dashboard dibangun dengan tiga prioritas utama: kemudahan interpretasi hasil oleh pengguna non-teknis, interaktivitas yang kaya, dan proses deployment yang efisien dan gratis.

9.1 Desain Dashboard

Dashboard CortiSoul dirancang dengan pendekatan Single Page Application (SPA) menggunakan `st.session_state` untuk navigasi multi-halaman tanpa reload. Desain mengutamakan keterbacaan, konsistensi visual, dan kemudahan eksplorasi data bagi pengguna teknis maupun non-teknis.

a. Prinsip Desain

1. Konsistensi visual: sistem warna teal-green-amber yang konsisten di seluruh halaman.
2. Hierarki informasi: dari ringkasan (Overview) ke detail (Performa Model, A/B Testing).
3. Responsive: CSS `clamp()` dan media queries untuk tampilan mobile dan desktop.
4. Interaktivitas: setiap halaman memiliki minimal 1 kontrol filter yang fungsional

b. Sistem Warna

Warna	Kode Hex	Penggunaan
Teal	#0D9488	Warna utama, aksen, border insight box, topbar gradient

Green	#10B981	Status sukses, highlight positif
Cyan	#06B6D4	Aksen sekunder, badge
Amber	#F59E0B	Peringatan, kondisi minor
Red	#EF4444	Error, kondisi kritis, target line pada chart
Purple	#8B5CF6	Elemen tambahan, kondisi personality disorder

c. Komponen UI Kustom

Dashboard menyuntikkan CSS kustom via `st.markdown()` untuk komponen yang tidak tersedia secara default di Streamlit:

1. Top Bar gradient: banner fixed di atas halaman dengan metrik kunci proyek.
2. Nav pills: tombol navigasi pill-style dengan state primary/secondary yang sinkron.
3. Metric cards: kartu matrix dengan tipografi Syne dan border atas berwarna.
4. Insight/Warning/Success box: kotak informasi dengan border kiri berwarna sesuai konteks.
5. Tag tokens: chip pill untuk menampilkan token eksklusif per kondisi

d. Struktur Navigasi

Dashboard memiliki 7 halaman yang dapat diakses melalui dua jalur: tombol navigasi horizontal di bagian atas konten, dan shortcut di sidebar.

Perpindahan halaman menggunakan `st.rerun()` untuk memperbarui tampilan secara instan.

Halaman	Konten Utama	Insight yang Disajikan
 Overview	4 metrik kunci, donut chart distribusi, alur metodologi 7 tahap	Gambaran cepat proyek: jumlah data, model terbaik, dan hasil akurasi
 Dataset	Tabel data dengan search, filter kelas, slider baris, download CSV	Kualitas data, distribusi kolom, dan jumlah missing values
 Distribusi Data	Bar chart / pie chart distribusi kelas, boxplot panjang teks per kondisi	Class imbalance antar kondisi, variasi panjang teks per kondisi mental
 Analisis Token	Top-10 kata representatif per kondisi (Word2Vec <code>most_similar</code>), token eksklusif per kondisi, heatmap overlap token antar kondisi, word cloud	Ciri khas linguistik yang membedakan setiap kondisi mental berdasarkan kemiripan vektor Word2Vec
 Performa Model	Perbandingan 4 kombinasi model, F1 per kelas, confusion pairs, CV Stratified 5-Fold	Model terbaik, kondisi yang sulit diklasifikasikan

 A/B Testing	Perbandingan metrik Word2Vec vs FastText, radar chart, McNemar Test + gauge p-value	Signifikansi statistik perbedaan antara dua metode word embedding
 Kesimpulan	2 jawaban penelitian, 6 rekomendasi pengembangan, checklist pencapaian	pencapaian Ringkasan akhir hasil penelitian dan arah pengembangan ke depan

e. Persyaratan Sistem

Dependensi	Versi Minimum	Fungsi
streamlit	>=1.30.0	Framework utama dashboard — navigasi halaman, metric cards, tabs, expander, download button, session state, st.rerun()
plotly	>=5.0.0	Semua visualisasi interaktif: bar chart, pie/donut chart, scatter plot, gauge indicator, radar chart, heatmap, dan subplot — via plotly.express, plotly.graph_objects, dan plotly.subplots.make_subplots
pandas	>=2.0.0	Load dataset CSV/Excel, filter dan pencarian data, kalkulasi statistik deskriptif, deteksi missing values

		dan duplikat, pivot table model performance
numpy	>=1.24.0	Simulasi distribusi panjang teks (fallback saat data tidak tersedia), operasi array pada visualisasi
glob	stdlib	Pencarian file dataset (CSV/Excel) secara otomatis di folder ../data/
os	stdlib	Resolusi path file untuk dataset dan folder gambar notebook (nb_images/)

f. Struktur Direktori

File / Folder	Keterangan
dashboard/cortisoul_dashboard.py	File utama dashboard Streamlit
dashboard/nb_images/	Folder gambar visualisasi dari notebook berisi hasil EDA (distribusi kelas, panjang teks, boxplot), word cloud, heatmap overlap token (Word2Vec & FastText), bar chart top-10 token (Word2Vec & FastText), token eksklusif, perbandingan performa model, confusion matrix, t-SNE, dan hasil A/B testing

data/clean_processed.csv	Dataset hasil preprocessing — jika tidak ada, dashboard menggunakan data hardcoded sebagai fallback (opsional)
Notebook.ipynb	Notebook analisis lengkap (EDA, modeling, A/B testing)
README.md	Dokumentasi proyek
requirements.txt	Daftar dependensi Python untuk deployment dashboard
url.txt	Link deployment dashboard

9.2. Implementasi Dashboard (Streamlit)

Dashboard interaktif dibangun menggunakan Streamlit, sebuah framework Python yang memungkinkan pembuatan aplikasi web data science secara cepat tanpa memerlukan pengetahuan frontend yang mendalam. Streamlit dipilih karena kemudahan integrasi dengan model machine learning berbasis Python dan proses deployment yang efisien.

9.3 Deployment ke Streamlit Cloud

Aplikasi di-deploy menggunakan Streamlit Cloud yang menyediakan hosting gratis untuk aplikasi Streamlit dengan integrasi langsung ke repository GitHub. Proses deployment dilakukan dengan menghubungkan repository ke Streamlit Cloud dan mengkonfigurasi environment dependencies melalui file requirements.txt.

10. Penutup

10.1. Kesimpulan

Proyek Cortisoul telah berhasil membangun pipeline analisis sentimen berbahasa Indonesia secara komprehensif, mulai dari preprocessing, EDA, vectorization, pemodelan, hingga deployment. Proses preprocessing dengan menggabungkan stopwords NLTK dan PySastrawi terbukti efektif menghasilkan teks yang bersih. A/B Testing menggunakan Stratified K-Fold 5 fold menunjukkan bahwa Word2Vec lebih unggul dibandingkan FastText sebagai metode vectorization pada dataset ini. Model BiLSTM berhasil mencapai akurasi di atas 90% dalam mengklasifikasikan teks jurnal ke dalam tiga kategori tingkat stres, dan platform Cortisoul telah berhasil di-deploy di Streamlit Cloud dalam kondisi yang berjalan dengan baik.

10.2. Rekomendasi Action Item

Dalam jangka pendek, disarankan untuk mengumpulkan data jurnal asli dari pengguna nyata, memperluas kamus normalisasi slang, serta menambahkan fitur enkripsi untuk menjamin privasi pengguna. Dalam jangka menengah, eksplorasi model IndoBERT sebagai alternatif BiLSTM perlu dilakukan, sekaligus mengembangkan fitur tren emosi dan rekomendasi konten self-help yang dipersonalisasi. Dalam jangka panjang, kolaborasi dengan profesional kesehatan mental untuk validasi klinis, implementasi sistem referral otomatis ke layanan profesional, serta pengembangan versi mobile application menjadi prioritas utama untuk memperluas dampak dan aksesibilitas platform Cortisoul.

Daftar Pustaka

- [1] T. G. Susilowati, N. U. Hasanat, and F. Psikologi, "Pengaruh Terapi Menulis Pengalaman Emosional Terhadap Penurunan Depresi pada Mahasiswa Tahun Pertama."
- [2] Rumah Sakit Pusat Pertamina, "Kesehatan Mental di Indonesia: Tantangan, Dampak, dan Solusi Mendesak," Rumah Sakit Pusat Pertamina (RSPP).
- [3] "PERBANDINGAN METODE VEKTORISASI PADA ANALISA SENTIMENT, STUDI KASUS : CYBERBULLYING PADA KOMENTAR INSTAGRAM."
- [4] D. Iskandar and A. Kurniawati, "Analisis Perbandingan Teknik Word2vec dan Doc2vec dalam Mengukur Kemiripan Dokumen Menggunakan Cosine Similarity," *Jurnal Teknologi Informasi dan Ilmu Komputer*, vol. 12, no. 1, pp. 133–144, Feb. 2025, doi: 10.25126/jtiik.2025129143.
- [5] R. Lumbantoruan, M. Puspita, S. Nababan, and L. A. Saragih, "Analisis Perbandingan FastText dan Word2Vec pada Sistem Temu Balik Informasi," *Seminar Nasional Sains Data*, vol. 2024, [Online]. Available: <https://www.kaggle.com/datasets/szymonjanowski/internet-articles-data-with-users-engagement/>
- [6] D. Oleh and H. Faizal, "IDENTIFIKASI CYBERBULLYING PADA MEDIA SOSIAL TWITTER MENGGUNAKAN LSTM DAN BILSTM," 2020.
- [7] A. H. Lubis, "Apa itu A/B Testing dalam Machine Learning," Blog Dosen Fakultas Teknik, Universitas Medan Area.